

FORECASTING LLM TOKEN DEMAND WITH CONVERSATION STATE

Time-Series Data Analysis Proposal

Team 4 / Lee Junsang · Seo Dael · Roh jonghyeon · Lim Jihun

BACKGROUND & MOTIVATION

- LLM 수요가 빠르게 늘고 있다
- 서버가 부족하면 응답 지연·실패, 남으면 전력 낭비 → 수요에 맞춰 늘리고 줄여야 한다
- 새 서버를 띄우는 데 수 분이 걸린다 → 사후 대응은 늦다, 몇 분 앞을 미리 알아야 한다
- 같은 요청 수라도 입력·출력 길이에 따라 부담이 다르다 → 입력·출력 토큰을 예측해야 한다

→ 그렇다면, 입력·출력 토큰 수요를 미리 알 수 있을까?

RELATED WORK

공통 공백: 네 연구 모두 진행 중인 대화의 상태로 다음 수요를 예측하지는 않았다

Prior work · Method & contribution	Limitation
BurstGPT · KDD 2025 — 실제 요청 로그 공개, 과거 집계로 요청 수·토큰 수 예측 (XGBoost)	집계 이력만 사용. 대화 상태를 더하면 나아지는지 확인 안 함,
DynamoLLM · HPCA 2025 — 요청 길이·부하에 맞춰 서버 수·GPU 설정 조정, SLO를 지키면서 에너지 53% 절감	이미 들어온 요청의 길이만 예측. 진행 중인 대화의 다음 수요는 안 다룸
PreServe · ICSE 2026 — 전체 토큰 수요와 개별 요청 길이를 계층적으로 예측, 선제적 자원 배정·라우팅과 연결	전체 수요는 예측하지만 대화 연결 정보는 쓰지 않음
SageServe · Microsoft 2025 — ARIMA로 수요 예측, 모델 재배포(약 10분)를 미리 시작하도록 서버 수 조정	1시간 단위 집계만 예측. 다음 10분 변동·입/출력 구분 없음

Research question:

집계 이력에 진행 중인 대화정보를 더하면,
다음 10분의 토큰 수요를 더 정확히 예측할 수 있는가?

OUR HYPOTHESIS

대화 정보를 추가하면 토큰 수요 예측이 더 좋아질까? — 같은 시점, 같은 모델로 $A \rightarrow B \rightarrow C$ 비교

Features	Model A	Model B	Model C
예측 방식	time series ML model 회귀 · 입력/출력 모델 따로 · 같은 튜닝 예산		
① 과거 수요 이력 요청 수·입력 토큰·완료 기준 출력 토큰의 지연값과 이동통계, 요청 길이 특성, 예측 시점의 시간대	BASELINE	●	●
② 활동 대화 수 최근 5 · 15 · 30분 동안 요청을 보낸 고유 대화 수		NEW	●
③ 대화 상태 요약 최근 30분 활동 대화의 마지막 요청 후 경과시간, 관측 요청 횟수, 첫 관측 후 경과시간, 마지막 입력 길이와 변화			NEW
검증 가설	기준 모델 BurstGPT 기반	H1 · B vs A 대화 수 → 오차 감소	H2 · C vs B 대화 상태 → 오차 감소

HOW THE LOG WAS COLLECTED

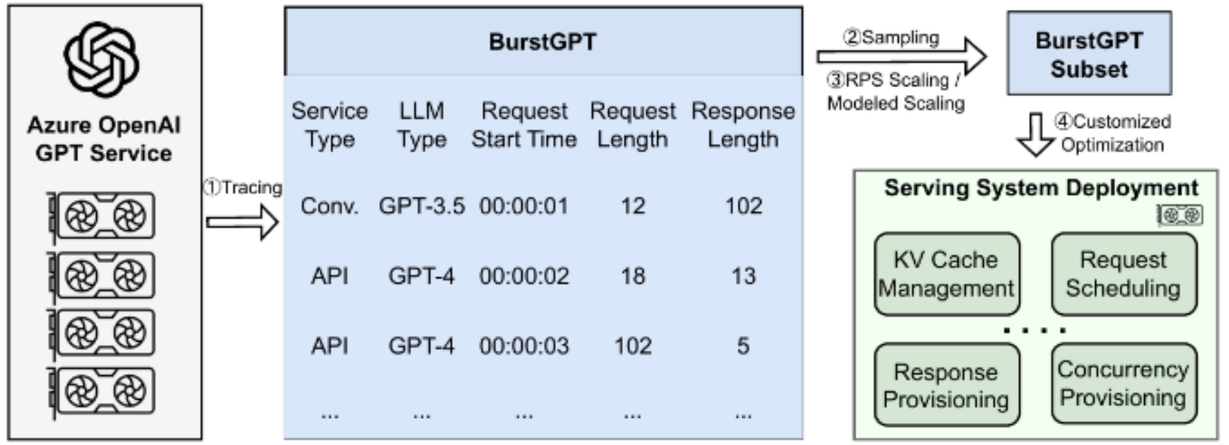
① 3,000명 이상이 쓰는 지역 GPT 서비스에
로깅 엔진 설치 (Azure OpenAI Service)

② 대화형·API 두 방식의 요청을 모두 기록

③ 요청 제출 시각, 입력·출력 토큰 수,
모델·서비스 종류를 실제 사용 중에 기록

WHY IT FITS to Time series analysis
시간 표시가 있는 요청, 토큰 수, 대화 연결 정보가
모두 있어 수요 변동과 시간 의존성을 분석할 수 있고,
최근 대화 활동이 단기 예측을 돕는지 검증할 수 있다.

Source: Wang et al., BurstGPT, KDD 2025 · v2.0 release



DATASET: BURSTGPT_3

Azure OpenAI 기반 실제 *GPT* 서비스 요청 로그 *(v2.0)*
*110*일 · *5,344,021*건, 그중 대화형 *233,617*건
*55,920*개 대화 세션 · *2*회 이상 대화 *36,086*개
요청 제출 시각 · 대화 *ID* · 입·출력 토큰 · 응답 시간

DATA FIELDS

Column	Description · 1 row = 1 request
Timestamp	기준일 자정 이후 요청 제출까지의 상대 초 (실제 날짜·요일은 알 수 없음, UTC+8)
Session ID	같은 대화의 요청을 잇는 대화 식별자 (사용자 ID 아님) → B·C 특징의 연결 키
Request / Response / Total tokens	입력 길이 / 최종 출력 길이 / 두 값의 합
Elapsed time	제출부터 최종 응답 완료까지의 초 (첫 토큰 시간 아님) → 완료 시각 = 제출 + Elapsed
Model	ChatGPT 또는 GPT-4
Log Type	Conversation log 또는 API log → 본 연구는 Conversation log만 사용

HOW WE USE IT

From request events to a forecasting dataset	
대화형 로그 233,617건을 주 분석 데이터로 쓴다. ID 유효성과 반복 대화 여부를 점검한다.	
원본 Timestamp의 1분 경계로 집계해 요청 수·입력·출력 토큰의 1분 이력을 만든다.	
Session ID로 과거 요청을 묶어 활동 대화 수와 대화 상태 요약을 만든다 (과거 관측만 사용).	
출력 길이는 응답이 완료된 뒤에만 특징에 쓴다. 미래 요청 정보는 특징에 넣지 않는다.	
매 1분마다 다음 10분에 도착할 요청의 입력 토큰 합·최종 출력 토큰 합을 예측한다.	

Information availability: 예측 시점 t에서 쓸 수 있는 정보만 쓴다

- 요청 정보는 $a_i < t$인 경우 사용한다.
- 최종 출력량은 $c_i < t$인 경우에만 사용한다.

FORECAST TARGET

매분, 다음 10분 동안 도착할 요청의 토큰 합을 예측한다.

Known at:
- Window end (t+10 min)
- After responses finish
- Forecast origin t

Quantity	Definition	Known at
Input demand I(t) — 다음 10분 입력 토큰 수요	[t, t+10분)에 도착한 요청의 입력 토큰 합	●
Output demand O(t) — 그 구간에 생성된 토큰량이 아니라, 도착한 요청들의 최종 출력량 (출력 0인 요청도 유지)	같은 요청들의 최종 출력 토큰 합 (도착 시각 기준으로 배정)	●
Forecast origin — 예측 시점과 갱신 주기	원본 Timestamp의 60초 경계마다 1회, 매 1분 갱신 (창이 겹침)	●
Label finalization — 학습에 쓸 수 있는 시점 (10분 출력 정답의 13.9%는 창 종료 이후에 완료된 응답 포함)	입력 정답: 10분 창이 종료된 후 확정 출력 정답: 10분 창이 종료되고, 해당 창의 모든 응답이 완료된 후 확정	●

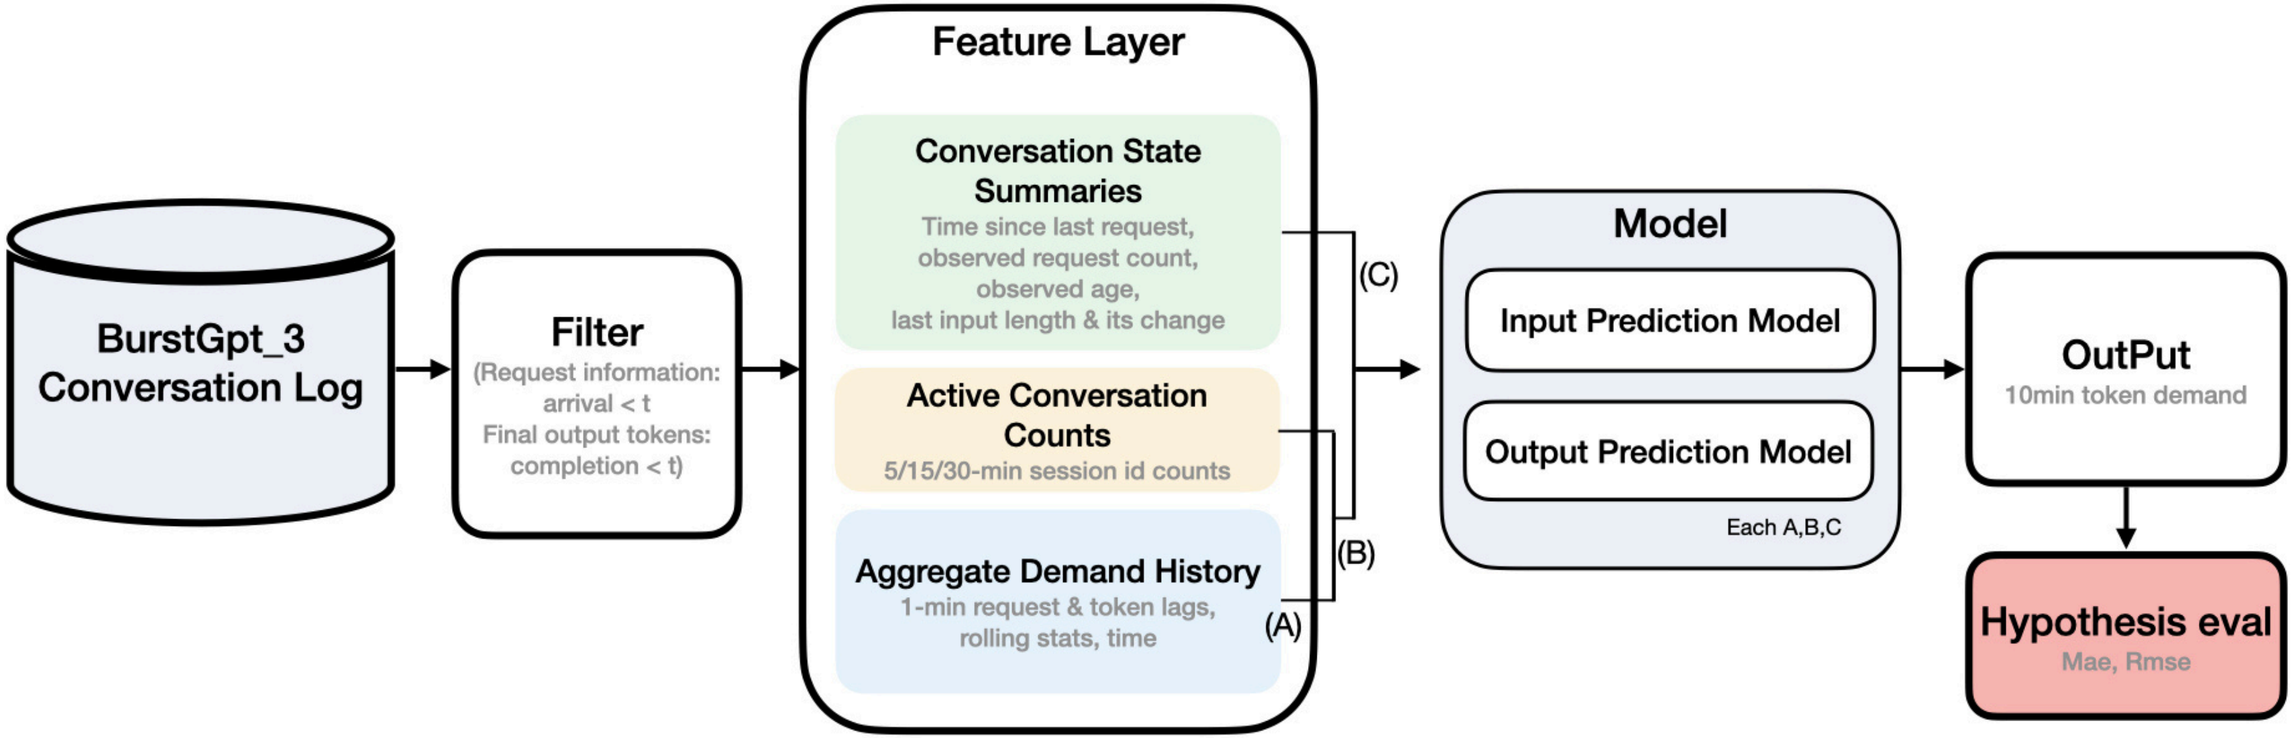
EVALUATION

같은 시점 · 같은 정답 · 같은 모델군 · 같은 튜닝 예산으로 $A \rightarrow B \rightarrow C$

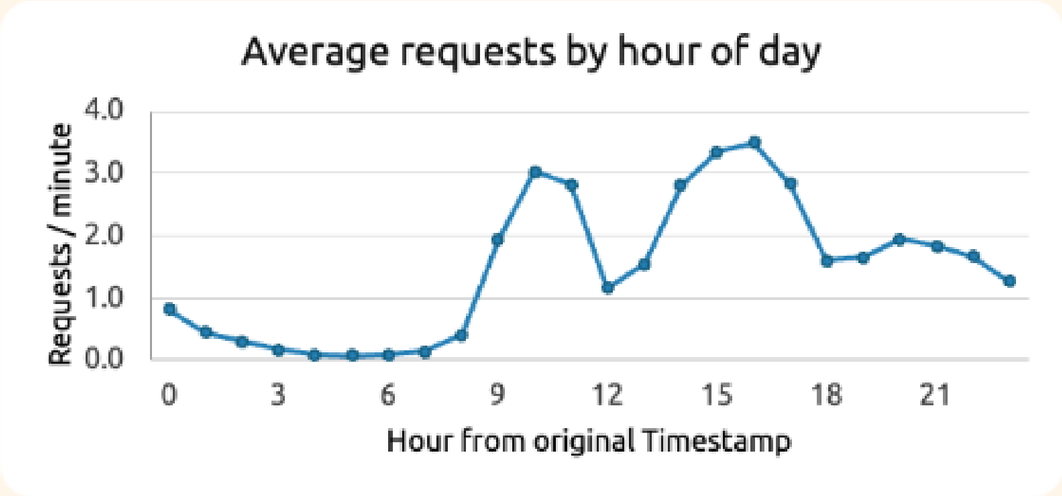
Why:
- Fair comparison
- No leakage
- Honest reporting

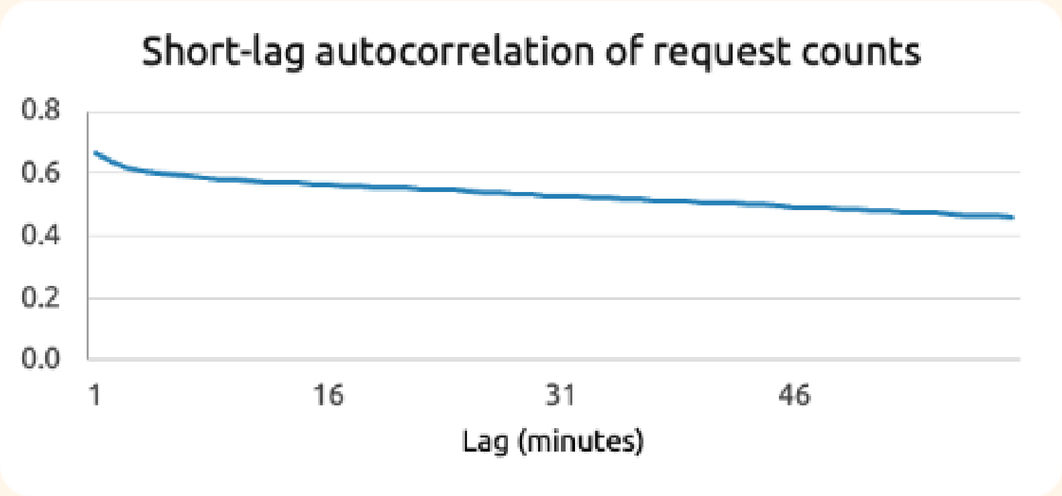
Design choice	Rule	Why
Chronological split — 학습 60% / 검증 20% / 평가 20%. 경계는 모델 성능을 보기 전에 고정한다	시간순 분할 검증 구간에서만 특징·설정 선택	●
Same conditions for A / B / C — 입력·출력 각각 XGBoost 회귀 (총 6개), 동일한 예측 시점·목적함수·탐색 범위·튜닝 예산 + Naive baseline	같은 적격 시점 같은 튜닝 예산	●
Metrics — MAE 주지표, RMSE 보조. 정답이 0인 구간이 있어 MAPE는 쓰지 않는다. 개선폭 B–A, C–B, C–A를 입력·출력별로 보고	입력·출력 따로 판단 시기별·고수요 구간 확인	●
Finalized labels only — 창이 닫히고 응답이 모두 완료된 표본만 학습. 겹치는 10분 창은 날짜별 짝지은 오차와 블록 bootstrap으로 다룬다	정답 확정 시점 검사 독립 표본 가정 안 함	●

PIPELINE OVERVIEW



EDA ① DEMAND HISTORY





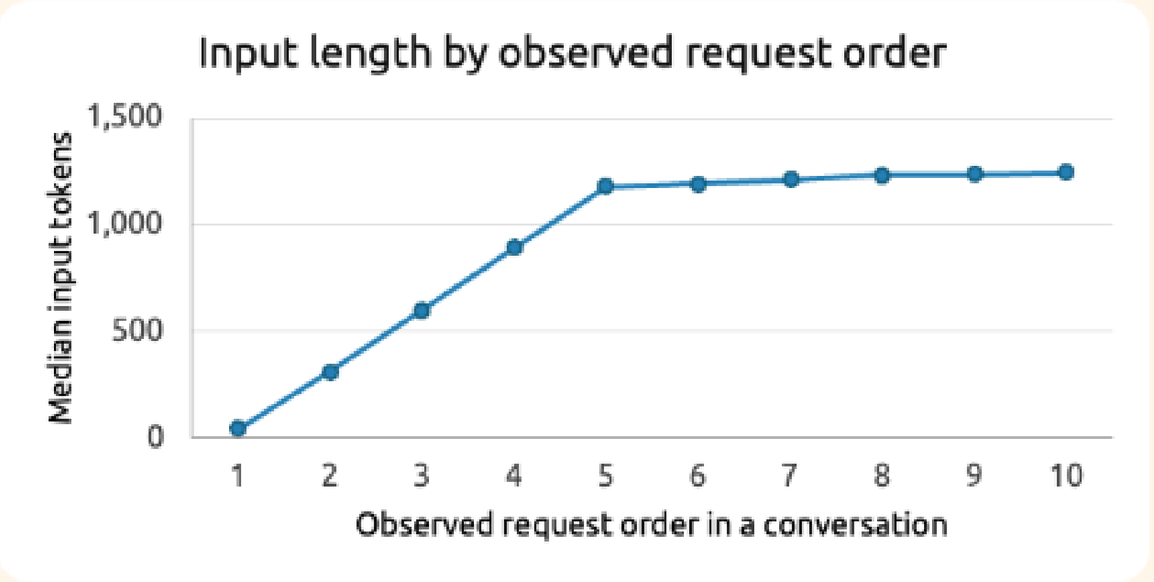
왜 우리 모델에 time, recent request 을 넣을까?

Average request by hour of day :
시간대에 따라 평균 요청 수에 차이가 있다.
낮에 요청이 많고 저녁과 새벽에 줄어드는 양상을 보인다.
→ use time to data input

Short-lag autocorrelation of request counts :
가까운 시점의 요청 수 사이에
자기상관이 크게 감소하지 않게 관측되고 있다.
→ use recent request data to input

EDA ② CONVERSATIONS

Conversation evidence	Value
Unique conversation IDs	55920
Conversations with 2+ requests	64.53%
Requests in repeated conversations (for all request)	91.51%
Observed follow-up gap, median	131 sec



계속 지속되는 대화:
전체 대화중 반복되는 대화가 64.5%였다.
전체 요청 수 중 repeated 요청이 91.5%였다.
반복 요청 사이의 간격의 median은 131초이다.
→ 최근에 이어지던 대화(~10min) 은 단기 수요를 예측하는 단서가 될 가능성이 있다.

Observed request order:
대화 중 몇번째로 관측된 요청인지에 따라 입력 토큰의 길이가 달라진다.
request order가 커짐에 따라 입력 길이의 중앙값이 크게 높아진다.

Based on this observation
B에는 최근에 요청이 관측된 대화의 수를 추가합니다.
C에는 각 대화의 마지막 요청이 얼마나 최근인지, 지금까지 몇 번 요청했는지, 마지막 입력 길이가 얼마인지를 추가해본다.

EDA ③ CORRELATIONS

Past predictor
최근 5분 요청 수와 최근 5분 활동 대화 수 둘다 입출력 토큰과 높은 상관관계를 보입니다.
→ 둘다 예측에 활용해볼 수 있는 후보

Exploratory Spearman correlations

Past predictor	Next 10m input	Next 10m output
최근 5분 요청 건수	0.822	0.832
최근 5분 활동 대화 수	0.825	0.841

하지만 **Past request count vs. active conversations (5 min) Spearman correlation = 0.978**

Based on this Result
같은 예측 대상과 시간순 데이터 분할, 모델에 대하여 각기 다른 input을 추가하여 입력·출력 토큰의 예측 오차를 각각 비교합니다.

B와 A를 비교하면 활동 대화 수의 추가 효과를, C와 B를 비교하면 대화 상태의 추가 효과를 확인할 수 있습니다.

WORKLOAD DISTRIBUTION

Plan 품질 점검 → 특징·정답 구성 → 분할·기준 모델 → A / B / C 비교 → 해석·보고

이준상	Model development — naive baseline, 입력·출력 XGBoost, 시간순 검증과 동일한 튜닝 예산
서다엘	Feature engineering & targets — 다음 10분 정답, 집계·세션 특징, 예측 시점 정보 가용성 보장
노종현	Preprocessing & EDA — 대화 로그 준비, 품질 점검, 요청·토큰 수요의 시간 패턴 분석
임지훈	Evaluation & interpretation — 특징 묶음·기간별 오차 비교, 대화 상태의 추가 가치 해석
Shared	실험 설계, 누출 검사, 재현성, 최종 보고서와 발표 준비

BEYOND THIS PROJECT

- 이번 프로젝트: 대화 상태가 다음 10분 입력·출력 토큰 예측 오차를 줄이는가
- 다루지 않는 것: 예측을 이용한 서버 수 조정, 응답 지연, 실제 전력 소비
- 부하에 맞춰 서버·GPU 설정을 바꾸면 에너지 53% 절감 (DynamoLLM, HPCA 2025)
- 그 조정이 선제적이려면 수요를 미리 알아야 한다 → 예측 가능성이 전제 조건

→ 후속 연구: 예측이 쓸 만하다면, 선제 조정이 전력·지연에서 실제 이득을 주는가?

Questions?